

Yapay Zeka Dersi Proje Raporu

1. Proje Başlığı

NASA C-MAPSS Veri Seti ile Turbofan Motor Kalan Kullanım Ömrü (RUL) Tahmini

2. Proje Ekibi


- Ad Soyad: Ayşe Atmaca
- Öğrenci Numarası: 241478117
- Bölüm / Sınıf: Yazılım Mühendisliği / 2
- Ekipteki Görev(ler): Literatür Araştırması ve Metodoloji, Veri Ön İşleme, Model Geliştirme ve Entegrasyon, Fizik Tabanlı Optimizasyon, Model Doğrulama ve Açıklanabilirlik

3. Proje Özeti

Bu projede, NASA C-MAPSS[1] turbofan motor veri seti kullanılarak uçak motorları için Kalan Kullanım Ömrü (RUL) tahmini gerçekleştirilmiştir. Çalışmanın amacı, motor arızalarını daha erken öngörerek uçuş güvenliğini artırmak ve bakım süreçlerini daha verimli hale getirmektir. Model yapısında BiLSTM+Attention, Transformer Encoder ve GRU Stacking Ensemble mimarileri birlikte kullanılmış; ayrıca tahminlerin fiziksel olarak tutarlı kalabilmesi için Physics-Informed Loss yaklaşımı uygulanmıştır. Özellikle farklı operasyon koşullarına sahip FD002 ve FD004 subsetlerinde elde edilen RMSE sonuçları, literatürde karşılaştırılan 16 güncel çalışma arasında en düşük hata değerleri arasında yer almıştır. Tüm subsetlerde ise başlangıç modellerine göre ortalama %7 oranında RMSE iyileşmesi elde edilmiştir.

4. Giriş

Turbofan motorlar, modern sivil ve askeri havacılık sistemlerinin temel itki bileşenlerinden biridir. Bu motorlarda meydana gelebilecek beklenmeyen arızalar; uçuş güvenliği, operasyon sürekliliği ve bakım maliyetleri açısından kritik risk oluşturmaktadır. Bu nedenle motor sağlığının sürekli izlenmesi ve arıza oluşmadan önce kalan kullanım ömrünün (Remaining Useful Life – RUL) tahmin edilmesi, havacılık sektöründe önemli bir araştırma alanı haline gelmiştir. Bu projede, NASA tarafından yayımlanan C-MAPSS veri seti kullanılarak turbofan motorlarının RUL tahmini için derin öğrenme tabanlı bir yaklaşım geliştirilmiştir.



Şekil 1. NASA C-MAPSS veri setinde kullanılan basitleştirilmiş turbofan motor yapısı [2], simülasyon ortamında modellenen motor modülleri ve alt sistem bağlantıları [2]

Bu konunun seçilmesindeki temel neden, havacılık mühendisliği ile yapay zekâ alanlarının birlikte kullanılabilirdiği gerçek bir mühendislik problemini inceleme isteğidir. Özellikle zaman serisi verileri üzerinde çalışan derin öğrenme modellerinin, motor degradasyon davranışlarını öğrenme konusunda önemli avantajlar sağladığı görülmektedir. Ayrıca NASA C-MAPSS veri seti, PHM literatüründe yaygın olarak kullanılan standart benchmark veri setlerinden biri olduğu için elde edilen sonuçların literatürdeki çalışmalarla doğrudan karşılaştırılması mümkün olmaktadır.

Çalışma kapsamında BiLSTM, Attention Mechanism, Transformer Encoder ve GRU tabanlı stacking ensemble mimarileri kullanılmıştır. Veri ön işleme aşamasında cluster normalization, sliding window ve sensör seçimi yöntemleri uygulanmıştır. Bunun yanında fiziksel olarak tutarlı tahminler elde edebilmek amacıyla Physics-Informed Loss yaklaşımı modele entegre edilmiştir. Çalışma yalnızca NASA C-MAPSS veri seti ile sınırlandırılmış olup gerçek zamanlı uçuş verileri ve farklı motor tipleri bu kapsamın dışında tutulmuştur.

5. Kullanılan Yöntem ve Teknolojiler

Bu çalışmada, zaman serisi tabanlı Kalan Kullanım Ömrü (RUL) tahmini için farklı derin öğrenme mimarileri birlikte kullanılmıştır. Model yapısında sıralı bağımlılıkları öğrenebilmek amacıyla Bidirectional Long Short-Term Memory (BiLSTM), uzun dönem ilişkileri yakalayabilmek amacıyla Transformer Encoder ve farklı model çıktılarının birleştirilmesi için GRU tabanlı stacking ensemble yaklaşımı tercih edilmiştir. Ayrıca modelin kritik zaman adımlarına odaklanabilmesi için Attention Mechanism uygulanmıştır. Fiziksel olarak tutarlı tahminler elde edebilmek amacıyla Physics-Informed Loss[3] yaklaşımı kullanılmıştır.

Proje Python programlama dili ile geliştirilmiştir. Derin öğrenme modellerinin oluşturulmasında PyTorch kütüphanesi kullanılmıştır. Veri ön işleme ve değerlendirme süreçlerinde NumPy, Pandas ve Scikit-learn kütüphanelerinden yararlanılmıştır. SHAP kütüphanesi ile sensör önem analizi gerçekleştirilmiş; Matplotlib kullanılarak eğitim eğrileri, performans grafikleri ve karşılaştırma görselleri oluşturulmuştur. Model eğitimleri Google Colab ortamında NVIDIA T4 ve L4 GPU altyapıları kullanılarak gerçekleştirilmiştir.


Çalışmada NASA tarafından yayımlanan C-MAPSS turbofan motor veri seti kullanılmıştır. Veri seti, farklı operasyon koşullarında çalışan turbofan motorlarına ait sensör verilerini içermektedir. FD001, FD002, FD003 ve FD004 olmak üzere dört farklı alt veri seti üzerinde çalışılmıştır. Veri ön işleme aşamasında sabit sensörlerin çıkarılması, sliding window yaklaşımı, cluster normalization ve ölçeklendirme işlemleri uygulanmıştır.

Tablo 1. NASA C-MAPSS veri setine ait alt veri kümeleri ve operasyon özellikleri.[4]

Veri Seti	Eğitim Motoru	Test Motoru	Operasyon Koşulu	Arıza Modu
FD001	100	100	1	1
FD002	260	259	6	1

FD003	100	100	1	2
FD004	249	248	6	2

Tablo 1’de NASA C-MAPSS veri setine ait alt veri kümeleri gösterilmektedir. FD001 ve FD003 tek operasyon koşulu içerirken, FD002 ve FD004 alt kümeleri 6 farklı operasyon koşulu içermektedir. Ayrıca FD003 ve FD004 veri setlerinde iki farklı arıza modu bulunmaktadır. Bu durum özellikle FD002 ve FD004 subsetlerinde modelleme problemini daha karmaşık hale getirmektedir. Bu nedenle FD002 ve FD004 subsetleri için cluster-based normalization yaklaşımı uygulanmıştır.



Şekil 2. RUL tahmini için önerilen hibrit derin öğrenme model mimarisi ve Model eğitimi öncesinde uygulanan veri ön işleme ve cluster normalization pipeline yapısı.

6. Sonuçlar ve Değerlendirme

Çalışma sonucunda FD001, FD002, FD003 ve FD004 veri setleri üzerinde başarılı RUL tahmin sonuçları elde edilmiştir. Model performansı RMSE, R^2 ve NASA Score metrikleri kullanılarak değerlendirilmiştir. Şekil 3.'de gösterimleri yapılmıştır.



Şekil 3. Sırasıyla: FD001-FD004 alt veri setleri için literatür tabanlı RMSE karşılaştırması[5], Önerilen modelden elde edilen gerçek RUL ve tahmin sonuçlarının karşılaştırılması

FD002 ve FD004 veri setlerinde elde edilen RMSE sonuçları, literatürde karşılaştırılan güncel çalışmalar arasında en düşük hata değerleri arasında yer almıştır. Özellikle çoklu operasyon koşullarına sahip FD004 subsetinde cluster normalization yaklaşımının önemli katkı sağladığı gözlemlenmiştir. Aşama bazlı analizlerde, başlangıç modeline kıyasla FD004 veri setinde yaklaşık %14,5 oranında RMSE iyileşmesi elde edilmiştir.

R^2 sonuçları incelendiğinde modelin gerçek degradasyon davranışını büyük ölçüde öğrenebildiği görülmektedir. Özellikle FD003 veri setinde elde edilen 0.848 R^2 değeri, modelin sensör değişimlerini başarılı şekilde takip ettiğini göstermektedir. NASA Score metriğinde ise geç tahminlerin daha ağır cezalandırılması nedeniyle çoklu operasyon koşullarına sahip veri setlerinde daha yüksek değerler oluşmuştur.



Şekil 4. Sırasıyla: Cluster Normalization ve Physics-Informed Loss sonrası elde edilen aşama bazlı RMSE iyileşmesi, FD001/2 veri seti için SHAP tabanlı sensör önem analizi.

Model çıktıları epoch-RMSE eğrileri, gerçek RUL–tahmin karşılaştırmaları, literatür kıyas grafikleri ve SHAP sensör analizleri ile görselleştirilmiştir. Yapılan analizlerde s11 (HPC çıkış basıncı) sensörünün tüm subsetlerde en kritik sensörlerden biri olduğu belirlenmiştir. Bu durum, fiziksel degradasyon davranışı ile uyumlu sonuçlar üretildiğini göstermektedir.

Bununla birlikte çalışma bazı sınırlılıklar da içermektedir. Model yalnızca NASA C-MAPSS veri seti üzerinde test edilmiş olup gerçek zamanlı uçuş verileri kullanılmamıştır. Ayrıca farklı motor tipleri ve çevresel koşullar için ek doğrulama çalışmaları gerekmektedir.

7. Yenilikçilik / Özgünlük Açıklaması

Bu çalışmanın temel özgünlüğü, farklı derin öğrenme mimarilerinin fizik tabanlı kısıtlarla birlikte hibrit bir yapı içerisinde birleştirilmesidir. Çalışmada BiLSTM+Attention ve Transformer Encoder modellerinden elde edilen tahminler, GRU tabanlı stacking ensemble yaklaşımı ile birleştirilmiş ve farklı operasyon koşullarında daha kararlı sonuçlar elde edilmiştir.

Projede özellikle FD002 ve FD004 veri setleri için cluster normalization yaklaşımı uygulanmıştır. Standart normalizasyon yöntemlerinin operasyon koşullarındaki değişimleri degradasyon olarak yorumlayabildiği gözlemlenmiş; bu nedenle operasyon koşullarına göre ayrı normalizasyon uygulanarak model performansı iyileştirilmiştir.

Bir diğerk önemli katkı ise Physics-Informed Loss yaklaşımıdır. Bu yöntemde motor kalan kullanım ömrünün fiziksel olarak artamayacağı bilgisi kayıp fonksiyonuna entegre edilmiştir. Böylece daha kararlı ve fiziksel açıdan tutarlı tahminler elde edilmiştir.

Ayrıca model kararlarının yorumlanabilmesi amacıyla SHAP tabanlı sensör önem analizi gerçekleştirilmiş ve s11 sensörünün tüm subsetlerde kritik rol oynadığı belirlenmiştir. Bu durum modelin yalnızca düşük hata üretmediğini, aynı zamanda fiziksel degradasyon davranışını anlamlı şekilde öğrenebildiğini göstermektedir.

8. Gelecek Çalışmalar

Bu çalışmanın gelecekte farklı yönlerden geliştirilmesi mümkündür. İlk olarak modelin gerçek zamanlı uçuş verileri üzerinde test edilmesi planlanmaktadır. Böylece motor sensör verileri geldikçe modelin kendini güncelleyebilmesi hedeflenmektedir.

İlerleyen çalışmalarda farklı motor tipleri ve farklı operasyon koşullarına sahip daha kapsamlı veri setleri ile ek doğrulama çalışmaları gerçekleştirilebilir. Ayrıca transfer learning yaklaşımı kullanılarak bir veri setinde eğitilen modelin farklı motor sistemlerine uyarlanması araştırılabilir.

Model güvenilirliğini artırmak amacıyla belirsizlik tahmini yöntemleri de sisteme entegre edilebilir. Böylece model yalnızca tahmin sonucu değil, aynı zamanda tahmin güven aralığı da üretebilir.

Bunun yanında fizik tabanlı simülasyon araçları ve mühendislik analizleri ile veri odaklı yapay zekâ modellerinin birlikte kullanılması planlanmaktadır. Özellikle COMSOL tabanlı termodinamik analizler ile sensör değişimlerinin fiziksel etkilerinin daha detaylı incelenmesi hedeflenmektedir.

9. Kaynakça

1. NASA Ames Prognostics Data Repository, "C-MAPSS Turbofan Engine Simulator Dataset."
2. A. Saxena, K. Goebel, D. Simon, N. Eklund, "Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation," IEEE International Conference on Prognostics and Health Management (PHM), 2008.
3. S. M. Lundberg, S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," NeurIPS, 2017.
4. S. Zheng, K. Ristovski, A. Farahat, C. Gupta, "Long Short-Term Memory Network for Remaining Useful Life Estimation," IEEE International Conference on Prognostics and Health Management (ICPHM), 2017.
5. O. Asif, S. A. Haider, S. R. Naqvi, J. F. W. Zak, K.-S. Kwak, and S. M. Riazul Islam, "A Deep Learning Model for Remaining Useful Life Prediction of Aircraft Turbofan Engine on C-MAPSS Dataset," IEEE Access, vol. 10, pp. 95061–95075, 2022.